


Deep Reinforcement Learning for Adaptive Urban Traffic Signal Control

應用深度強化學習於都市交通號誌動態控制

報告人：周達弘、吳濬濠

授課教授：陳煥


本專案旨在透過深度強化學習技術，解決都市交通號誌動態控制的核心挑戰。



Background: Urban Traffic Congestion in Taiwan

台灣都市交通壅 塞背景

交通壅塞是台灣都會區
普遍且可量化的嚴重都
市移動問題。



Background: Rush Hour Inefficiency

尖峰時段交通效率低落



早尖峰 10公里行駛時間

31分35秒




晚尖峰 10公里行駛時間

39分28秒



平均車速

16.7 km/h



車流對時變需求與路口瓶頸高度敏感

尖峰時段極低的平均車速顯示，現有路口消化車流的能力已達瓶頸。

Motivation: Road Safety and Intersection Conflicts

道路安全與路口衝突

393,918

件交通事故

524,485

人受傷

2,950

人死亡 (含行人 366 人)

113年 (2024) 數據顯示

不良號誌控制

急煞 / 長時間停等 /
車流交織

行人與行車風險

號誌最佳化除了提升效率，也是降低路口衝突與保障行人安全的重要手段。

Motivation: Environmental Impact and Emissions

環境影響與運輸碳排



不良號誌



長時間停等 /
怠速增加

反覆加速與煞車



碳排飆升

智慧化交通控制是落實都市低碳治理的關鍵途徑。

Effectiveness of Existing Smart Signals in Taiwan

台灣智慧號誌既有成效



2021–2024 累計節省
2,762萬延人小時

台灣在地經驗已證實自適應號誌的價值，為本研究應用 DRL 進一步優化提供合理性基礎。

Research Problem and Objectives

研究問題與目標

現有瓶頸

依賴預設規則或人工設計策略，難以應對非線性且複雜的動態車流。

From Rule-based
to AI Learning
(Data-driven)

01

建立以 Deep Reinforcement Learning 為基礎的自適應號誌控制架構。

02

將號誌控制精準建模為 Markov Decision Process (MDP)。


03

透過 SUMO 模擬環境驗證模型在降低延滯、排隊長度與碳排上的成效。

本研究旨在以資料驅動方法，取代傳統基於規則的交通號誌控制。

Related Work Overview

相關研究總覽




交通號誌技術正從靜態排程走向動態感知，再邁向自主學習。

Limitation of Fixed-Time Signal Control

固定時制號誌控制的限制



- 運作機制：
事先設定紅綠黃燈週期，嚴格依照時間表運行。
- 優點：實作簡單、成本低。



固定時制在尖峰時段或突發車流下，會造成嚴重的路口延滯與資源錯配。

Limitation of Actuated Signal Control

感應式號誌控制的限制

運作機制：

利用地磁或影像偵測車流，具備初步彈性，可減少離峰空等。



缺乏全局視野
決策基於剛性規則，無法主動預判並優化整體路網的長期效率。

感應式號誌是被動反應 (Reactive)，無法針對路網進行長期最佳化。


自適應號誌控制的限制

章節：2. Related Work

Key Message：傳統自適應系統的極限在於人為設計規則的邊界，難以處理全局複雜性。

- 依據即時車流調整週期、綠燈秒數與相位順序。
- 具備實務成效，於台灣已有縮短旅行時間的實證。
- 核心瓶頸：多數系統仍依賴 Heuristic Optimization 與人工設計規則。
- 面對非線性、多路口交互影響及極端車流時，適應能力受限。

傳統自適應控制流程




Emergence of Reinforcement Learning-Based Control 強化學習式號誌控制的興起

章節：2. Related Work

- **突破規則限制**：將控制視為 Agent 與 Environment 的互動。
- **運作機制**：Agent 觀察 State、採取 Action、獲得 Reward。
- **自主優化**：透過反覆試錯學習長期最佳策略。
- **動態適應**：能自主適應極端與動態車流。

Key Message：RL 能透過獎勵機制學會複雜交通環境中的長期最佳化策略。



Comparative Analysis of Signal Control Technologies

號誌控制技術比較分析

章節：2. Related Work

Key Message：DRL 在動態適應與長期最佳化上具備超越傳統方法的潛力。

比較維度	Fixed-Time (固定)	Actuated (感應)	Adaptive (自適應)	RL-Based (Ours)
Dynamic Adaptability	無 (靜態排程)	局部 (被動反應)	高 (依據即時數據)	極高 (動態感知) ✓
Long-term Optimization	差	差	中 (依賴規則品質)	優 (全局累積獎勵) ✓
Dependency on Human Rules	絕對依賴	高度依賴	高度依賴	低 (資料驅動) ✓
Scalability	易	中	難 (規則複雜化)	高 (神經網路泛化) ✓
Handle Complex Traffic	差	弱	中	強 ✓


System Architecture Overview

系統架構總覽

章節：3. Proposed Scheme

本研究提出整合式 DRL 控制架構：

1. Traffic Simulation (SUMO)：實體路況模擬。
2. State Extraction：擷取即時特徵。
3. DRL Agent：神經網路決策。
4. Signal Control：轉換為實體指令。
5. Reward Evaluation：計算效益以更新模型。



Key Message：系統形成 closed-loop control system，使 Agent 能持續從環境中學習與優化。

Markov Decision Process (MDP) Formulation

Markov Decision Process 建模

章節：3. Proposed Scheme



- **核心橋樑**：將都市號誌控制建模為 Markov Decision Process。



- **問題定義**：解決不確定環境中的 sequential decision-making problem。





- **時間推進**：系統以 time-step t 推進，在 $S_t \rightarrow A_t \rightarrow R_t \rightarrow S_{t+1}$ 間循環。



- **數學表示**：定義為 Tuple $\langle S, A, P, R, \gamma \rangle$ 。

Key Message：MDP 是將實體交通問題轉換為數學最佳化問題的核心橋樑。




MDP Elements: Agent & Environment

MDP 元素：Agent 與 Environment

章節：3. Proposed Scheme

Key Message：兩者的互動模擬了控制器與真實車流的動態博弈。



State Representation (S)


狀態表示設計

章節：3. Proposed Scheme

State Vector (S_t) 表徵即時交通特徵：

- Queue length (排隊車輛數)
- Waiting time (平均等待秒數)
- Current signal phase (目前號誌燈態)
- Remaining green time (剩餘綠燈時間)
- Vehicle speed (接近路口之平均車速)

Key Message：精準的 State 設計讓 Agent 具備預判壅塞的全方位視野。




Action Space Design (A)


動作空間設計

章節：3. Proposed Scheme


Action Space (A_t) 定義 Agent 可執行的指令。本專案採 Discrete Action Space 以降低運算複雜度，確保訓練收斂。




$a = 0$ (延長目前綠燈)



$a = 1$ (南北向通行)



$a = 2$ (東西向通行)



$a = 3$ (其他特定相位)

Key Message：離散動作空間在保證多相位切換的同時，有效控制了模型的運算負荷。


Reward Function Design (R)

獎勵函數設計

章節：3. Proposed Scheme

- Reward (R_t) 是引導 Agent 行為的核心。
- 若只獎勵通過車輛數，將犧牲支道公平性。
- 採 Joint Reward Function 最小化多重指標：
 - Average waiting time (效率)
 - Queue length (防堵塞)
 - Travel delay (旅行時間)
 - Emissions (環境永續)

$$R_t = - \left(w_1 \times Queue + w_2 \times Delay + w_3 \times Emission \right)$$



Key Message：綜合獎勵函數兼顧了交通效率、路權公平性與環境永續。


Policy Formulation (π)

策略函數設計

章節：3. Proposed Scheme


- 映射關係：Policy 是從狀態 s 決定動作 a 的機率分佈 $\pi(a|s)$ 。
- 神經網路：透過 Deep Neural Networks 逼近未知的最佳策略 π^* 。
- 最佳化目標：最大化 expected cumulative discounted reward。
- 應用實踐：訓練後即成為適應動態車流的智慧控制器。

Key Message：訓練完成的 Policy 即是能即時適應動態車流的智慧號誌大腦。




Deep Reinforcement Learning Algorithms

深度強化學習演算法



Deep Q-Network (DQN)

- ✓ Value-based method
- ✓ 學習 State-Action 價值函數 $Q(s, a)$
- ✓ 適合離散動作空間 (Discrete Action Space)




Proximal Policy Optimization (PPO)

- ✓ Policy-based (Actor-Critic) method
- ✓ 直接優化 Policy $\pi(a|s)$
- ✓ 限制策略更新幅度，訓練穩定適應複雜環境

DQN: Deep Q-Network as Baseline

DQN 作為基準模型



專案定位

作為 Baseline，用於驗證單一路口基本號誌切換學習能力。

潛在限制

面對多路口或連續動作空間時，容易面臨維度災難與收斂不穩。

Key Message : DQN 架構單純且具備高度解釋性，是驗證 RL 應用於號誌控制可行性的絕佳起點。

PPO: Proximal Policy Optimization

PPO 主力演算法

Actor


Actor (決策者)：負責輸出切換號誌的 Policy 機率分佈。

Critic

Critic (評估者)：預測目前交通狀態的 Value，引導 Actor 修正。

Role

專案定位：本研究的核心方法，專注應對尖峰突發車流與極端不平衡情境。



Key Message：PPO 在穩定性與複雜動態環境適應性上的強大優勢，使其成為本專案智慧號誌控制的核心大腦。

Simulation Environment: SUMO

模擬環境：SUMO



平台簡介：Simulation of Urban Mobility (開源、微觀、連續交通模擬)。




微觀模擬能力：支援真實車輛跟車模型 (Car-following)、變換車道、行人穿越。



數據採集：於虛擬環境精準收集 Waiting Time, Queue Length, Travel Delay, CO2 Emissions。

Key Message：SUMO 提供高擬真度的微觀交通沙盒環境，讓 Agent 能在無安全風險下進行百萬次試錯學習。



Toolchain: SUMO-RL Framework


技術工具鏈：SUMO-RL



Key Message：透過 SUMO-RL 橋接工具，我們成功將嚴謹的交通工程模擬器標準化為現代 AI 訓練生態系的工作流。


Experimental Scenarios Design

實驗場景設計



場景 A：單一標準路口

測試基本收斂能力與防碰撞號誌切換邏輯。



場景 B：極端流量不均

測試路權公平性，避免為了吞吐量導致支道無止盡空等。



場景 C：動態尖離峰

模擬早晚尖峰交替；測試模型即時適應力與策略切換彈性。

Key Message：涵蓋從常態到極端動態的壓力測試場景，全面驗證 RL 演算法應對真實世界不確定性的能力。

Evaluation Metrics & Baselines

評估指標與基準方法

Baselines (基準方法)

- Fixed-Time Control (固定時制)
- Actuated Control (感應式控制)
- Random Policy
- DQN (演算法對照)

Measurement



效率 (Efficiency)

Average Waiting Time, Queue Length, Throughput



環境 (Environment)

(Environment)

CO2 Emissions 減少量



演算法 (Algorithm)

Convergence Speed, Cumulative Reward

Key Message : 透過多維度評估體系，全面檢驗交通提升、減碳效益與 AI 演算法的實務穩健性。

Expected Contributions

預期貢獻

依賴固定規則

尖峰極度壅塞

高延滯高碳排



方法創新 (Methodology):

成功將號誌控制轉為 MDP 框架，
提出交通全景感知 State 向量。



效能突破 (Performance):

預期 PPO 顯著降低 Average Waiting
Time，優於感應式控制。



永續發展 (Sustainability):

減少怠速與延滯，有效降低都市運輸溫
室氣體排放，呼應淨零碳排治理。

Key Message：本研究建立了一個兼顧「交通效率」與「環境永續」的智慧化決策框架。

Limitations and Future Work

限制與未來研究

Limitations - The Present



- **Sim-to-Real 落差**：模擬器難以完全涵蓋台灣特有的違停、機車鑽車縫與行人違規。
- **單一路口侷限**：目前專注於獨立路口，尚未解決上游放行導致下游壅塞的連鎖效應。



Future Work - The Vision



- **Multi-Agent RL (MARL)**：引入多代理強化學習，實現多路口協調與全域「綠波 (Green Wave)」。
- **大規模城市路網**：將環境遷移至 CityFlow 模擬器進行全城等級大腦調度測試。

Key Message：本研究為智慧號誌奠定了堅實的單節點基礎，未來將朝向多路口協調與全域路網大腦邁進。

Final Summary

總結

This project proposes a Deep Reinforcement Learning-based adaptive traffic signal control framework that formulates urban intersection management as a Markov Decision Process, allowing an intelligent agent to learn signal control policies that reduce waiting time, queue length, travel delay, and environmental impact under dynamic traffic conditions.

Thank You for Listening!
Q&A

深度強化學習將重新定義都市交通的控制大腦。